

EMSI Casablanca

École Marocaine des Sciences de l'Ingénieur (EMSI)
Casablanca

Module :
Deep Learning

Rapport de Projet
Apprentissage Profond :
MLP, CNN et Architectures Récurrentes
pour la Classification, la Vision et le Séquentiel

Réalisé par : *Bouka Wenn*

Encadré par : *Battal*

Filière : *Intelligence Artificielle*

Année universitaire : **2025 – 2026**

Date de remise : 18 juin 2026

Table des matières

Liste des figures	4
Liste des tableaux	5
1 Introduction générale	6
1.1 Problématique	6
1.2 Organisation du rapport	6
2 Objectifs du projet	6
2.1 Objectifs généraux	6
2.2 Objectifs théoriques	7
2.3 Objectifs pratiques	7
3 Méthodologie générale	7
3.1 Démarche scientifique commune	7
3.1.1 Phase 1 — Préparation des données	7
3.1.2 Phase 2 — Implémentation de l'architecture	7
3.1.3 Phase 3 — Entraînement et optimisation	8
3.1.4 Phase 4 — Évaluation	8
3.1.5 Phase 5 — Analyse critique	8
3.2 Environnement de développement	8
4 Partie I — Perceptron Multicouche et Données Tabulaires	9
4.1 Présentation du jeu de données et préparation des données	9
4.1.1 Le dataset Breast Cancer Wisconsin	9
4.1.2 Prétraitement et découpage	9
4.2 Fondements théoriques	10
4.2.1 L'abstraction <code>nn.Module</code>	10
4.2.2 Rétropropagation du gradient	10
4.2.3 Sauvegarde avec <code>state_dict</code>	10
4.3 Implémentation du MLP	10
4.3.1 <code>nn.Sequential</code> — Architecture linéaire	10
4.3.2 Classe personnalisée héritant de <code>nn.Module</code>	11
4.4 Stratégies d'initialisation des poids	11
4.4.1 Enjeux théoriques	11
4.4.2 Comparaison expérimentale	11
4.5 Résultats expérimentaux	12
4.5.1 Métriques de classification	12
4.5.2 Matrice de confusion	13

4.6	Analyse critique	13
4.7	Question de synthèse	14
5	Partie II — Réseaux de Neurones Convolutifs et Vision par Ordinateur	14
5.1	Présentation du jeu de données Fashion-MNIST	14
5.2	Fondements théoriques de la convolution	15
5.2.1	Opération de convolution discrète	15
5.2.2	Paramètres de la couche convolutive	15
5.2.3	Pooling	15
5.3	Implémentations manuelles versus PyTorch	15
5.3.1	Corrélation croisée manuelle	15
5.3.2	Max Pooling manuel	16
5.4	Architecture CNN proposée	16
5.5	Étude expérimentale	17
5.5.1	Protocole d'entraînement	17
5.5.2	Historique d'entraînement	17
5.6	Évaluation	19
5.6.1	Métriques globales	19
5.6.2	Matrice de confusion	19
5.7	Visualisation des cartes d'activation	20
5.8	Comparaison MLP versus CNN	20
5.9	Analyse critique	21
5.10	Question de synthèse	21
6	Partie III — Architectures Récurrentes et Modélisation Séquentielle	22
6.1	Présentation du corpus	22
6.2	Fondements théoriques	22
6.2.1	Modèle de langage et perplexité	22
6.2.2	Rétropropagation à travers le temps (BPTT)	22
6.3	Implémentation des architectures récurrentes	23
6.3.1	Cellule RNN simple	23
6.3.2	Cellule LSTM	23
6.3.3	Cellule GRU	23
6.4	Comparaison des architectures récurrentes	24
6.5	Effet du gradient clipping	24
6.6	Système Seq2Seq avec encodeur-décodeur	24
6.6.1	Architecture générale	24
6.6.2	Teacher Forcing	25
6.7	Stratégies de décodage	25
6.7.1	Décodage glouton (<i>greedy search</i>)	25

6.7.2 Recherche par faisceau (<i>beam search</i>)	25
6.8 Évaluation	26
6.8.1 Perplexité et BLEU	26
6.9 Analyse critique	26
6.10 Question de synthèse	27
7 Discussion transversale	27
7.1 Liens entre les trois paradigmes architecturaux	27
7.2 Tableau de synthèse comparatif	28
8 Limites générales du travail	28
9 Conclusion générale	29
A Annexe expérimentale	30
A.1 Hyperparamètres détaillés par expérience	30
A.2 Tableau comparatif supplémentaire : régularisation	31
Bibliographie	32

Table des figures

1	Pipeline méthodologique général commun aux trois parties du projet.	7
2	Comparaison de la convergence (perte vs époques) pour trois stratégies d'initialisation des poids : Gaussienne, Constante et Xavier.	12
3	Matrice de confusion du MLP (initialisation Xavier) sur l'ensemble de test. . . .	13
4	Historique d'entraînement du CNN sur Fashion-MNIST : perte (gauche) et exactitude (droite) en fonction du nombre d'époques.	18
5	Matrice de confusion normalisée du CNN sur l'ensemble de test de Fashion-MNIST.	19
6	Cartes d'activation de la première couche convolutive (Conv1, 32 filtres) pour une image de test de la classe <i>Baskets</i>	20
7	Cartes d'activation de la deuxième couche convolutive (Conv2, 64 filtres) pour la même image de test.	20
8	Évolution de la perplexité de validation au cours de l'entraînement pour les trois architectures récurrentes : RNN, LSTM et GRU.	24
9	Effet du gradient clipping sur la norme du gradient au cours de l'entraînement d'un LSTM, avec et sans clipping ($c = 1$).	24
10	Schéma comparatif des trois paradigmes architecturaux : MLP, CNN et RNN/LSTM.	28

Liste des tableaux

1	Environnement logiciel et matériel utilisé pour les expériences.	8
2	Métriques de classification du MLP (Breast Cancer Wisconsin, ensemble de test).	13
3	Architecture du CNN appliqué à Fashion-MNIST.	16
4	Métriques de classification du CNN sur l'ensemble de test de Fashion-MNIST.	19
5	Comparaison des performances du MLP et du CNN sur Fashion-MNIST.	20
6	Comparaison des architectures récurrentes sur la tâche de modélisation du langage.	24
7	Évaluation des stratégies de décodage sur le corpus de test.	26
8	Tableau de synthèse comparative des trois architectures étudiées.	28
9	Hyperparamètres de la Partie I (MLP, Breast Cancer Wisconsin).	30
10	Hyperparamètres de la Partie II (CNN, Fashion-MNIST).	30
11	Hyperparamètres de la Partie III (LSTM, modélisation du langage).	30
12	Effet des techniques de régularisation sur les performances du CNN (Fashion-MNIST).	31

1 Introduction générale

L'essor du deep learning au cours de la dernière décennie constitue l'une des avancées les plus marquantes de l'intelligence artificielle moderne. Porté par la disponibilité croissante de données massives, la puissance de calcul des unités graphiques (GPU) et la maturation des frameworks open-source tels que PyTorch et TensorFlow, l'apprentissage profond a transformé de manière radicale les pratiques dans des domaines aussi variés que la vision par ordinateur, le traitement automatique du langage naturel, la bioinformatique ou encore la robotique.

Dans ce contexte, le présent rapport s'inscrit dans le cadre du module *Deep Learning* dispensé à l'École Marocaine des Sciences de l'Ingénieur (EMSI) de Casablanca, pour l'année universitaire 2025-2026. Il rend compte d'un projet de fin de module articulé autour de trois grandes familles d'architectures neuronales : les perceptrons multicouches (MLP), les réseaux de neurones convolutifs (CNN) et les architectures récurrentes (RNN, LSTM, GRU, Seq2Seq). Chaque famille est étudiée à travers un jeu de données spécifique, choisi pour ses propriétés pédagogiques et sa représentativité applicative.

1.1 Problématique

Si les architectures neuronales profondes ont démontré leur efficacité empirique sur un large spectre de tâches, leur conception et leur mise en œuvre soulèvent des questions fondamentales qui restent d'une grande actualité : *Comment choisir l'architecture adaptée à la nature des données ? Quels sont les effets des stratégies d'initialisation sur la convergence ? Dans quelle mesure les mécanismes de régularisation et de clipping améliorent-ils la stabilité de l'entraînement ?*

Ces interrogations constituent le fil directeur du projet. Elles invitent à dépasser la simple reproduction d'exemples pour adopter une démarche expérimentale rigoureuse, fondée sur la comparaison contrôlée de variantes architecturales et d'hyperparamètres.

1.2 Organisation du rapport

Le présent rapport est structuré en trois parties principales, précédées d'une présentation des objectifs et de la méthodologie générale, et suivies d'une discussion transversale et d'une conclusion :

- **Partie I** — Le perceptron multicouche (MLP) est appliqué au jeu de données tabulaires *Breast Cancer Wisconsin*, un problème de classification binaire en oncologie ;
- **Partie II** — Le réseau convolutif (CNN) est utilisé pour la classification d'images sur le jeu de données *Fashion-MNIST* ;
- **Partie III** — Les architectures récurrentes (RNN, LSTM, GRU) et le paradigme encodeur-décodeur (Seq2Seq) sont étudiés sur des données séquentielles textuelles.

Chaque partie suit une progression identique : présentation des données, fondements théoriques, implémentation, résultats expérimentaux et analyse critique. Ce parallélisme structurel facilite la comparaison inter-architecturale et renforce la cohérence scientifique du document.

2 Objectifs du projet

2.1 Objectifs généraux

Ce projet poursuit deux familles d'objectifs complémentaires : des objectifs théoriques, visant à consolider la compréhension des mécanismes fondamentaux du deep learning, et des objectifs pratiques, orientés vers la maîtrise des outils d'implémentation et d'évaluation.

2.2 Objectifs théoriques

1. **Maîtriser les fondements mathématiques** des réseaux de neurones : rétropropagation du gradient, descente de gradient stochastique, fonctions d'activation, et fonctions de perte.
2. **Comprendre les opérations de convolution** et leur rôle dans l'extraction hiérarchique de caractéristiques spatiales, notamment le concept de champ récepteur, les effets du *padding* et du *stride*.
3. **Appréhender la dynamique des gradients** dans les réseaux récurrents : problèmes de gradient évanouissant ou explosif, mécanismes de porte (LSTM, GRU) et rétropropagation à travers le temps (BPTT).
4. **Analyser comparativement** trois paradigmes architecturaux (MLP, CNN, RNN/LSTM/GRU) à travers la notion de géométrie des données et d'invariances à apprendre.

2.3 Objectifs pratiques

1. **Partie I (MLP)** : Implémenter un perceptron multicouche en PyTorch avec `nn.Sequential` et une classe personnalisée héritant de `nn.Module` ; comparer plusieurs stratégies d'initialisation des poids et évaluer leurs effets sur la convergence.
2. **Partie II (CNN)** : Concevoir et entraîner une architecture convolutive de type LeNet amélioré sur Fashion-MNIST ; analyser les cartes d'activation (*feature maps*) et comparer les performances au MLP.
3. **Partie III (RNN/LSTM/GRU/Seq2Seq)** : Implémenter et comparer des architectures récurrentes sur une tâche de modélisation du langage ; construire un système Seq2Seq avec mécanisme de *teacher forcing* et évaluer les stratégies de décodage.

3 Méthodologie générale

3.1 Démarche scientifique commune

Afin de garantir la comparabilité et la reproductibilité des expériences menées dans les trois parties, une démarche méthodologique commune a été adoptée, articulée autour de cinq phases successives (voir Figure 1).

FIGURE 1 – Pipeline méthodologique général commun aux trois parties du projet.

3.1.1 Phase 1 — Préparation des données

La qualité des données conditionne directement la performance des modèles. Chaque jeu de données fait l'objet d'une analyse exploratoire préalable (statistiques descriptives, distribution des classes, détection des valeurs manquantes), suivie d'un prétraitement adapté : normalisation ou standardisation pour les données tabulaires et images, tokenisation et encodage pour les données textuelles. Un découpage rigoureux en ensembles d'entraînement, de validation et de test est systématiquement effectué pour éviter toute fuite d'information (*data leakage*).

3.1.2 Phase 2 — Implémentation de l'architecture

L'implémentation est réalisée en Python avec le framework PyTorch (version ≥ 2.0). Deux styles de programmation sont explorés : l'API séquentielle `nn.Sequential`, adaptée aux archi-

tectures linéaires simples, et la définition de classes personnalisées héritant de `nn.Module`, qui offre toute la flexibilité nécessaire pour les architectures plus complexes (CNN, LSTM, Seq2Seq). Le respect des bonnes pratiques d'ingénierie (reproductibilité via `torch.manual_seed()`, sauvegarde de `state_dict()`, gestion des périphériques CPU/GPU) est assuré tout au long du développement.

3.1.3 Phase 3 — Entraînement et optimisation

L'entraînement suit le cycle classique *forward pass* → calcul de la perte → *backward pass* → mise à jour des paramètres via un optimiseur (Adam ou SGD avec momentum). Les hyperparamètres clés (taux d'apprentissage, taille de batch, nombre d'époques, dropout, weight decay) sont choisis par validation croisée ou par recherche en grille (*grid search*) sur l'ensemble de validation. Pour les architectures récurrentes, un *gradient clipping* est appliqué afin de stabiliser l'entraînement.

3.1.4 Phase 4 — Évaluation

L'évaluation des modèles mobilise un ensemble de métriques adapté à chaque tâche :

- Pour la classification (Parties I et II) : exactitude (*accuracy*), précision, rappel, F1-score et matrice de confusion.
- Pour la modélisation du langage (Partie III) : perplexité et score BLEU.

Les résultats sont systématiquement présentés sous forme de tableaux comparatifs et de visualisations graphiques.

3.1.5 Phase 5 — Analyse critique

Au-delà de la simple présentation des résultats, chaque partie se conclut par une analyse critique argumentée : interprétation des métriques, identification des sources d'erreur, confrontation aux résultats de la littérature et proposition de pistes d'amélioration. Cette dimension réflexive est essentielle à la démarche scientifique.

3.2 Environnement de développement

Les expériences ont été conduites dans l'environnement suivant :

TABLE 1 – Environnement logiciel et matériel utilisé pour les expériences.

Composant	Version / Détail
Langage	Python 3.11
Framework DL	PyTorch 2.2
Environnement	Jupyter Notebook / Google Colab
Accélérateur	GPU NVIDIA T4 (Colab) / CPU
Bibliothèques annexes	NumPy, Pandas, Matplotlib, Scikit-learn
Contrôle de version	Git / GitHub

4 Partie I — Perceptron Multicouche et Données Tabulaires

4.1 Présentation du jeu de données et préparation des données

4.1.1 Le dataset Breast Cancer Wisconsin

Le jeu de données *Breast Cancer Wisconsin (Diagnostic)* est un référentiel classique de l'apprentissage automatique, disponible dans la bibliothèque `scikit-learn` ainsi que sur le dépôt UCI Machine Learning Repository. Il contient **569 observations** décrivant des caractéristiques nucléaires de masses mammaires, extraites par une technique d'aspiration à l'aiguille fine (FNA). Chaque observation est représentée par **30 attributs numériques** continus, calculés à partir de 10 mesures de base (rayon, texture, périmètre, aire, régularité, compacité, concavité, points concaves, symétrie, dimension fractale), chacune déclinée en trois statistiques : valeur moyenne, erreur standard et valeur extrême.

La variable cible est binaire : **0 (bénin)** ou **1 (malin)**. La distribution des classes est légèrement déséquilibrée (62,7 % bénin vs 37,3 % malin), ce qui impose de recourir à des métriques au-delà de la simple exactitude pour une évaluation rigoureuse.

4.1.2 Prétraitement et découpage

Le pipeline de préparation des données comprend les étapes suivantes :

1. **Vérification de l'intégrité** : absence de valeurs manquantes confirmée.
2. **Standardisation** : toutes les features sont centrées-réduites ($\mu = 0$, $\sigma = 1$) via un `StandardScaler` ajusté *exclusivement* sur l'ensemble d'entraînement afin d'éviter toute contamination de l'ensemble de test.
3. **Découpage** : 80 % entraînement / 20 % test, avec stratification sur la variable cible pour préserver la distribution des classes dans chaque sous-ensemble.

```
1 from sklearn.datasets import load_breast_cancer
2 from sklearn.model_selection import train_test_split
3 from sklearn.preprocessing import StandardScaler
4 import torch
5
6 data = load_breast_cancer()
7 X, y = data.data, data.target
8
9 X_train, X_test, y_train, y_test = train_test_split(
10     X, y, test_size=0.2, random_state=42, stratify=y
11 )
12
13 scaler = StandardScaler()
14 X_train = scaler.fit_transform(X_train)
15 X_test = scaler.transform(X_test)
16
17 X_train_t = torch.tensor(X_train, dtype=torch.float32)
18 y_train_t = torch.tensor(y_train, dtype=torch.float32).unsqueeze(1)
```

Listing 1 – Chargement et prétraitement du dataset Breast Cancer.

4.2 Fondements théoriques

4.2.1 L'abstraction `nn.Module`

En PyTorch, tout réseau de neurones est modélisé comme une sous-classe de `torch.nn.Module`. Cette abstraction offre une gestion automatique du graphe de calcul (via `autograd`), une sérialisation facilitée des paramètres (`state_dict`) et une interface uniforme pour le mode entraînement / évaluation. La méthode `forward()` définit le passage avant du réseau.

4.2.2 Rétropropagation du gradient

La rétropropagation (*backpropagation*) est l'algorithme fondamental qui permet de calculer les gradients de la fonction de perte $\mathcal{L}$ par rapport à chaque paramètre θ du réseau. Elle s'appuie sur la règle de la chaîne dérivative appliquée au graphe de calcul orienté acyclique (DAG). Pour un réseau à L couches, le gradient de la perte par rapport aux paramètres de la couche l s'écrit :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}^{(l)}} \cdot \left(\mathbf{a}^{(l-1)} \right)^\top \quad (1)$$

où $\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}$ est la pré-activation et $\mathbf{a}^{(l-1)}$ est l'activation de la couche précédente. La mise à jour des paramètres suit la règle de descente de gradient :

$$\mathbf{W}^{(l)} \leftarrow \mathbf{W}^{(l)} - \eta \frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} \quad (2)$$

où η est le taux d'apprentissage. Dans le cadre de ce projet, l'optimiseur Adam [7] est privilégié pour ses propriétés de convergence adaptative.

4.2.3 Sauvegarde avec `state_dict`

La sérialisation des paramètres entraînés est assurée par `torch.save(model.state_dict(), path)`. Cette approche est préférée à la sauvegarde de l'objet modèle entier car elle garantit la portabilité et la compatibilité entre versions de PyTorch.

4.3 Implémentation du MLP

4.3.1 `nn.Sequential` — Architecture linéaire

```

1 import torch.nn as nn
2
3 model_seq = nn.Sequential(
4     nn.Linear(30, 64),
5     nn.ReLU(),
6     nn.Dropout(0.3),
7     nn.Linear(64, 32),
8     nn.ReLU(),
9     nn.Dropout(0.3),
10    nn.Linear(32, 1),
11    nn.Sigmoid()
12 )

```

Listing 2 – MLP défini avec `nn.Sequential`.

4.3.2 Classe personnalisée héritant de `nn.Module`

```

1 class MLP(nn.Module):
2     def __init__(self, input_dim=30, hidden=[64, 32], dropout=0.3):
3         super(MLP, self).__init__()
4         layers = []
5         prev = input_dim
6         for h in hidden:
7             layers += [nn.Linear(prev, h), nn.ReLU(), nn.Dropout(dropout
8                             )]
9             prev = h
10            layers.append(nn.Linear(prev, 1))
11            layers.append(nn.Sigmoid())
12            self.net = nn.Sequential(*layers)
13
14    def forward(self, x):
15        return self.net(x)

```

Listing 3 – MLP défini comme classe héritant de `nn.Module`.

La classe personnalisée offre une flexibilité accrue : il est possible d’y intégrer des connexions résiduelles (*skip connections*), des branches parallèles ou des mécanismes d’attention, qui ne sont pas directement exprimables avec la syntaxe `nn.Sequential`.

4.4 Stratégies d’initialisation des poids

4.4.1 Enjeux théoriques

L’initialisation des poids constitue un facteur déterminant de la vitesse et de la stabilité de la convergence. Une initialisation nulle ou uniforme inadaptée peut conduire à la *symmetry breaking failure* (tous les neurones apprennent la même fonction) ou à l’explosion / évanouissement des gradients dès les premières itérations. Trois stratégies ont été comparées dans ce projet :

- **Initialisation Gaussienne** : $W_{ij} \sim \mathcal{N}(0, 0.01)$. Simple mais peu adaptée aux couches profondes, elle peut induire une variance des activations croissante ou décroissante couche par couche.
- **Initialisation Constante** : $W_{ij} = c$ (typiquement $c = 0.1$). Brise la symétrie seulement si un biais non nul est utilisé ; rarement utilisée en pratique.
- **Initialisation de Xavier (Glorot) [5]** : $W_{ij} \sim \mathcal{U}\left[-\sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}, +\sqrt{\frac{6}{n_{\text{in}}+n_{\text{out}}}}\right]$. Conçue pour maintenir la variance des activations constante à travers les couches, elle est théoriquement optimale pour les activations linéaires et tanh.

$$\text{Var}(W) = \frac{2}{n_{\text{in}} + n_{\text{out}}} \quad (3)$$

4.4.2 Comparaison expérimentale

La Figure 2 présente les courbes de perte d’entraînement et de validation pour les trois stratégies d’initialisation, sur 100 époques.



FIGURE 2 – Comparaison de la convergence (perte vs époques) pour trois stratégies d’initialisation des poids : Gaussienne, Constante et Xavier.

On observe que l’initialisation de Xavier conduit à une convergence nettement plus rapide et plus stable que les deux alternatives. L’initialisation gaussienne avec une petite variance ($\sigma = 0.01$) engendre une phase de démarrage plus lente, la perte initiale étant relativement élevée, ce qui s’explique par le fait que les gradients propagés en arrière sont trop faibles pour induire des mises à jour significatives. L’initialisation constante présente, quant à elle, le comportement le plus erratique : les couches tendent à apprendre des représentations redondantes pendant plusieurs dizaines d’époques avant de se différencier. En revanche, Xavier garantit d’emblée une variance des activations équilibrée, ce qui confirme les prédictions théoriques de [5] et illustre concrètement l’importance du choix de l’initialisation dans les réseaux de profondeur modérée.

4.5 Résultats expérimentaux

4.5.1 Métriques de classification

Le Tableau 2 présente les métriques d’évaluation obtenues sur l’ensemble de test pour le MLP entraîné avec l’initialisation de Xavier.

TABLE 2 – Métriques de classification du MLP (Breast Cancer Wisconsin, ensemble de test).

Modèle	Accuracy	Précision	Rappel	F1-Score
MLP (Gaussien)	0.956	0.951	0.972	0.961
MLP (Constant)	0.947	0.941	0.963	0.952
MLP (Xavier)	0.974	0.971	0.986	0.978

4.5.2 Matrice de confusion

FIGURE 3 – Matrice de confusion du MLP (initialisation Xavier) sur l'ensemble de test.

La Figure 3 révèle que le modèle commet très peu de faux négatifs (cas malins classifiés comme bénins), ce qui est crucial dans un contexte médical où le coût d'un faux négatif est particulièrement élevé. Le rappel élevé (0.986) sur la classe maligne confirme cette propriété. Les quelques faux positifs observés (cas bénins classifiés comme malins) sont inhérents à l'optimisation du seuil de décision, qui pourrait être ajusté selon les exigences cliniques.

4.6 Analyse critique

Les résultats obtenus avec le MLP sur le dataset Breast Cancer Wisconsin sont globalement satisfaisants et s'inscrivent dans la gamme des performances rapportées dans la littérature pour ce jeu de données. Une exactitude de 97,4 % avec l'initialisation de Xavier représente une performance compétitive par rapport aux méthodes classiques d'apprentissage automatique (SVM : $\approx 97-98\%$, Random Forest : $\approx 96-97\%$) appliquées au même benchmark.

Cependant, plusieurs nuances méritent d'être soulevées. En premier lieu, la taille relativement modeste du dataset (569 observations, 30 features) limite la puissance statistique des comparaisons : les différences de performance entre les trois stratégies d'initialisation, bien que cohérentes sur le plan théorique, pourraient ne pas être statistiquement significatives si l'on répliquait l'expérience avec différentes graines aléatoires (*random seeds*). Il conviendrait de procéder à une validation croisée à k plis ($k = 10$) et de reporter les intervalles de confiance pour des conclusions plus robustes.

En second lieu, l'architecture MLP traitant les 30 features de manière complètement connectée ne capture aucune structure relationnelle entre les attributs. Or, certaines features sont fortement corrélées (aire, périmètre, rayon) : une architecture intégrant des mécanismes de sélection de features (ex. *attention*) ou une réduction préalable de dimensionnalité (ACP) pourrait conduire à de meilleures performances de généralisation tout en réduisant le nombre de paramètres.

Par ailleurs, le dataset présente un déséquilibre de classes modéré qui n'a pas fait l'objet d'un traitement spécifique au-delà de la stratification du découpage. Des techniques de rééchantillonnage (SMOTE) ou l'utilisation d'une fonction de perte pondérée (`BCEWithLogitsLoss(pos_weight=...)`) pourraient améliorer les performances sur la classe minoritaire.

Enfin, il importe de souligner l'écart entre les métriques sur l'ensemble de validation et sur l'ensemble de test, observé notamment pour l'initialisation constante. Cet écart, bien que modeste, suggère un sur-ajustement partiel, que la régularisation par dropout ne suffit pas entièrement à contenir. L'ajout d'une régularisation L_2 (*weight decay*) dans l'optimiseur Adam constituerait une piste d'amélioration directe.

4.7 Question de synthèse

Question : Dans quelle mesure le choix de la stratégie d'initialisation des poids influence-t-il la qualité et la vitesse de convergence d'un MLP, et comment ce choix s'articule-t-il avec la profondeur du réseau et la fonction d'activation utilisée ?

Réponse :

D'un point de vue théorique, l'initialisation des poids d'un réseau de neurones détermine l'état initial du paysage des pertes (*loss landscape*) depuis lequel démarre l'optimisation. Une initialisation inadaptée peut placer le réseau dans des zones de saturation des fonctions d'activation (pour sigmoid ou tanh) ou provoquer une amplification / atténuation exponentielle de la variance des activations couche par couche. Ce dernier phénomène, connu sous le nom d'explosion ou d'évanouissement des gradients, est d'autant plus prégnant que le réseau est profond.

Sur le plan méthodologique, les trois stratégies comparées illustrent des philosophies différentes. L'initialisation gaussienne naïve ignore la structure du réseau et peut conduire à des gradients trop faibles dès les premières itérations, allongeant significativement la phase de "warm-up" de l'entraînement. L'initialisation constante, quant à elle, viole le principe de brisure de symétrie : des neurones identiquement initialisés calculent des gradients identiques et convergent vers des représentations redondantes, un phénomène qui ne peut être atténué que progressivement.

L'initialisation de Xavier [5], en revanche, est fondée sur une analyse rigoureuse des flux de variance dans un réseau linéaire. En calibrant la variance des poids en fonction du nombre de neurones entrants et sortants, elle garantit que la variance du signal se conserve à travers les couches en mode propagation avant, et que la variance du gradient se conserve en rétropropagation. Ce double compromis explique sa supériorité empirique observée dans nos expériences.

Il convient toutefois de nuancer cette analyse. L'initialisation de Xavier est optimale pour des activations linéaires ou symétriques autour de zéro (tanh). Pour des activations rectifiées (ReLU), l'initialisation de Kaiming He [6], qui corrige le facteur de variance d'un facteur 2 pour tenir compte de l'annulation des activations négatives, est théoriquement préférable. Dans notre cas, l'utilisation de ReLU combinée à l'initialisation de Xavier donne néanmoins d'excellents résultats, ce qui suggère qu'avec une profondeur modérée (2-3 couches cachées) et un dropout, les différences entre ces deux schémas d'initialisation tendent à s'estomper.

5 Partie II — Réseaux de Neurones Convolutifs et Vision par Ordinateur

5.1 Présentation du jeu de données Fashion-MNIST

Fashion-MNIST [8] est un jeu de données de référence proposé par Zalando Research comme alternative plus difficile au célèbre MNIST de chiffres manuscrits. Il comprend **70 000 images en niveaux de gris** de dimension 28×28 pixels, réparties en **10 classes** d'articles vestimentaires : T-shirt/haut, Pantalon, Pull, Robe, Manteau, Sandale, Chemise, Baskets, Sac et Bottine. La partition officielle distingue 60 000 images d'entraînement et 10 000 de test, avec une distribution parfaitement équilibrée (6 000 images par classe).

Par rapport à MNIST, Fashion-MNIST présente une variabilité intra-classe plus élevée et des similarités inter-classes plus importantes (ex. Chemise vs T-shirt, Sandale vs Baskets), ce qui en fait un benchmark substantiellement plus discriminant pour évaluer la capacité des modèles à capturer des représentations visuelles fines.

Le prétraitement appliqué comprend une normalisation des intensités de pixels dans l'intervalle $[0, 1]$, suivie d'une standardisation channel-wise ($\mu = 0.2860$, $\sigma = 0.3530$ pour Fashion-

MNIST). Des augmentations de données (*data augmentation*) — retournement horizontal aléatoire et recadrage aléatoire — sont appliquées lors de l'entraînement pour améliorer la généralisation.

5.2 Fondements théoriques de la convolution

5.2.1 Opération de convolution discrète

Une convolution 2D entre une carte d'entrée $\mathbf{X}$ et un noyau $\mathbf{K}$ de dimensions $k_h \times k_w$ produit une carte de sortie $\mathbf{Y}$ selon :

$$Y[i, j] = \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} X[i+m, j+n] \cdot K[m, n] \quad (4)$$

En pratique, les couches convolutives de PyTorch implémentent une *corrélacion croisée* (sans retournement du noyau), fonctionnellement équivalente à la convolution pour l'apprentissage de représentations.

5.2.2 Paramètres de la couche convolutive

Trois hyperparamètres gouvernent la géométrie de sortie d'une couche convolutive :

- **Padding** p : ajout de zéros en périphérie de la carte d'entrée. Avec $p = (k - 1)/2$, on préserve les dimensions spatiales (*same padding*).
- **Stride** s : pas de déplacement du noyau. Un stride $s > 1$ sous-échantillonne la carte de sortie d'un facteur s .
- **Dilatation** d : espacement entre les éléments du noyau, permettant d'augmenter le champ récepteur sans accroître le nombre de paramètres.

La dimension de sortie pour une entrée de taille n , avec noyau k , padding p et stride s , vaut :

$$\left\lfloor \frac{n + 2p - k}{s} \right\rfloor + 1 \quad (5)$$

5.2.3 Pooling

Les couches de pooling réduisent les dimensions spatiales de la représentation, conférant une invariance partielle aux translations locales. Le *max pooling* sélectionne le maximum sur une fenêtre, tandis que l'*average pooling* en calcule la moyenne. Le max pooling est généralement préféré car il transmet le signal d'activation le plus fort, ce qui s'avère crucial pour la détection de features locales.

5.3 Implémentations manuelles versus PyTorch

5.3.1 Corrélacion croisée manuelle

```

1 import torch
2
3 def cross_correlation_2d(X, K):
4     kh, kw = K.shape
5     Y = torch.zeros(X.shape[0] - kh + 1, X.shape[1] - kw + 1)
6     for i in range(Y.shape[0]):

```



```

7         for j in range(Y.shape[1]):
8             Y[i, j] = (X[i:i+kh, j:j+kw] * K).sum()
9     return Y

```

Listing 4 – Implémentation manuelle de la corrélation croisée 2D.

Cette implémentation explicite, bien qu’inefficace pour des usages en production, illustre directement l’équation (4) et permet de vérifier la cohérence des résultats avec la couche `nn.Conv2d` de PyTorch.

5.3.2 Max Pooling manuel

```

1 def max_pool_2d(X, pool_size=2, stride=2):
2     H, W = X.shape
3     out_h = (H - pool_size) // stride + 1
4     out_w = (W - pool_size) // stride + 1
5     Y = torch.zeros(out_h, out_w)
6     for i in range(out_h):
7         for j in range(out_w):
8             Y[i, j] = X[i*stride:i*stride+pool_size,
9                         j*stride:j*stride+pool_size].max()
10    return Y

```

Listing 5 – Implémentation manuelle du max pooling 2D.

5.4 Architecture CNN proposée

L’architecture retenue s’inspire du réseau LeNet-5 [1], enrichi de couches de Batch Normalization et de Dropout pour améliorer la régularisation et la stabilité de l’entraînement. Le Tableau 3 en présente le détail couche par couche.

TABLE 3 – Architecture du CNN appliqué à Fashion-MNIST.

Couche	Type	Filtres / Unités	Sortie spatiale	Activation
1	Conv2d (3×3, pad=1)	32	28×28	ReLU
2	BatchNorm2d	32	28×28	—
3	MaxPool2d (2×2)	—	14×14	—
4	Conv2d (3×3, pad=1)	64	14×14	ReLU
5	BatchNorm2d	64	14×14	—
6	MaxPool2d (2×2)	—	7×7	—
7	Conv2d (3×3, pad=1)	128	7×7	ReLU
8	BatchNorm2d	128	7×7	—
9	Flatten	—	6 272	—
10	Linear	256	—	ReLU + Drop
11	Linear	10	—	Softmax (log)

```

1 class CNN(nn.Module):
2     def __init__(self):
3         super(CNN, self).__init__()
4         self.features = nn.Sequential(
5             nn.Conv2d(1, 32, 3, padding=1), nn.BatchNorm2d(32), nn.ReLU
6             (),

```

```

6         nn.MaxPool2d(2),
7         nn.Conv2d(32, 64, 3, padding=1), nn.BatchNorm2d(64), nn.ReLU
          (),
8         nn.MaxPool2d(2),
9         nn.Conv2d(64, 128, 3, padding=1), nn.BatchNorm2d(128), nn.
          ReLU()
10    )
11    self.classifier = nn.Sequential(
12        nn.Flatten(),
13        nn.Linear(128*7*7, 256), nn.ReLU(), nn.Dropout(0.5),
14        nn.Linear(256, 10)
15    )
16    def forward(self, x):
17        return self.classifier(self.features(x))

```

Listing 6 – Définition du CNN avec `nn.Module`.

5.5 Étude expérimentale

5.5.1 Protocole d'entraînement

Le modèle est entraîné pendant 30 époques avec l'optimiseur Adam ($lr = 10^{-3}$, weight decay $= 10^{-4}$), une taille de batch de 128 et la fonction de perte `CrossEntropyLoss`. Un scheduler de taux d'apprentissage de type `ReduceLROnPlateau` (patience = 5, facteur = 0.5) est utilisé pour adapter le taux d'apprentissage lorsque la perte de validation stagne.

5.5.2 Historique d'entraînement

La Figure 4 présente l'évolution de la perte et de l'exactitude sur les ensembles d'entraînement et de validation au cours des 30 époques.



FIGURE 4 – Historique d’entraînement du CNN sur Fashion-MNIST : perte (gauche) et exactitude (droite) en fonction du nombre d’époques.

On observe une convergence régulière et stable des deux courbes (entraînement et validation) sans signe apparent de sur-ajustement jusqu’à l’époque 20. À partir de l’époque 25, un léger écart entre les courbes d’entraînement et de validation commence à se former, suggérant le début d’un sur-ajustement modéré. L’activation du scheduler de taux d’apprentissage aux alentours de l’époque 15 (visible par le changement de pente) explique l’accélération de la convergence observée dans la seconde moitié de l’entraînement. Ce comportement confirme l’efficacité du Batch Normalization et du Dropout comme régularisateurs implicites.

5.6 Évaluation

5.6.1 Métriques globales

TABLE 4 – Métriques de classification du CNN sur l'ensemble de test de Fashion-MNIST.

Classe	Précision	Rappel	F1	Support
T-shirt/haut	0.84	0.87	0.86	1000
Pantalon	0.99	0.98	0.99	1000
Pull	0.85	0.83	0.84	1000
Robe	0.91	0.93	0.92	1000
Manteau	0.87	0.88	0.87	1000
Sandale	0.99	0.98	0.99	1000
Chemise	0.74	0.72	0.73	1000
Baskets	0.96	0.97	0.97	1000
Sac	0.99	0.98	0.98	1000
Bottine	0.97	0.98	0.97	1000
Moyenne macro	0.91	0.91	0.91	10000

5.6.2 Matrice de confusion




FIGURE 5 – Matrice de confusion normalisée du CNN sur l'ensemble de test de Fashion-MNIST.

La Figure 5 met en lumière plusieurs patterns remarquables. Les classes à géométrie distinctive (Pantalon, Sandale, Sac, Bottine) atteignent des taux de classification quasi-parfaits ($F1 \geq 0.97$), ce qui s’explique par des signatures visuelles peu ambiguës pour les couches convolutives. En revanche, la classe *Chemise* présente le taux de confiance le plus faible ($F1 = 0.73$), et ses confusions sont principalement dirigées vers *T-shirt/haut* et *Pull*, classes avec lesquelles elle partage une structure topologique similaire. Ce résultat illustre la limite fondamentale des CNN pour des classes sémantiquement proches mais visuellement similaires : en l’absence de données de profondeur ou de contexte sémantique, la discrimination repose entièrement sur des différences de texture et de contour, qui peuvent être insuffisantes.

5.7 Visualisation des cartes d’activation

FIGURE 6 – Cartes d’activation de la première couche convolutive (Conv1, 32 filtres) pour une image de test de la classe *Baskets*.

FIGURE 7 – Cartes d’activation de la deuxième couche convolutive (Conv2, 64 filtres) pour la même image de test.

L’analyse des cartes d’activation (Figures 6 et 7) révèle la hiérarchie progressive des représentations apprises. Les filtres de la première couche (Figure 6) répondent principalement aux contours orientés — horizontaux, verticaux et diagonaux — ce qui correspond aux détecteurs de Gabor de bas niveau observés dans les premières couches de tout CNN suffisamment entraîné. Les cartes activées dans la deuxième couche (Figure 7) présentent des patterns plus abstraits : certains filtres semblent spécialisés dans la détection de la lacet ou de la semelle, des caractéristiques sémantiquement plus riches. Cette progression hiérarchique, de features locales vers des représentations globales, constitue le cœur du pouvoir expressif des CNN et justifie leur supériorité sur les MLP pour les données spatiales.

5.8 Comparaison MLP versus CNN

TABLE 5 – Comparaison des performances du MLP et du CNN sur Fashion-MNIST.

Modèle	Accuracy	F1 macro	Paramètres	Temps/époque
MLP (3 couches, 512-256-10)	0.882	0.880	$\approx 670K$	≈ 4 s
CNN (LeNet amélioré)	0.913	0.912	$\approx 1.8M$	≈ 18 s

La supériorité du CNN (+3,1 points d’exactitude) s’explique par son biais inductif intrinsèque : les paramètres partagés des convolutions encodent une invariance à la translation locale, particulièrement adaptée aux données images où la même feature peut apparaître à différentes positions de l’image. Le MLP, en traitant chaque pixel comme une feature indépendante, ignore totalement la structure spatiale et doit apprendre ces invariances de manière implicite, ce qui nécessite davantage de données et de capacité du modèle. Par conséquent, le CNN atteint de meilleures performances avec un rapport qualité-paramètres plus favorable.

5.9 Analyse critique

Les performances obtenues par notre CNN (accuracy $\approx 91,3\%$) se situent dans la plage haute des résultats rapportés pour des architectures de complexité comparable sur Fashion-MNIST, la performance de l'état de l'art se situant autour de 95-96 % pour des réseaux plus profonds (ResNet, WideResNet) avec des augmentations de données plus agressives.

Plusieurs axes d'amélioration peuvent être identifiés. Premièrement, l'ajout de connexions résiduelles (*skip connections*) à la ResNet permettrait d'entraîner des architectures plus profondes sans souffrir du problème de dégradation du gradient, ouvrant la voie à des représentations plus riches. Deuxièmement, l'emploi d'augmentations de données plus diversifiées (rotations légères, déformations élastiques, *cutout*, *mixup*) a démontré empiriquement un gain de 1 à 2 points d'exactitude sur ce benchmark. Troisièmement, le transfert d'apprentissage depuis un modèle pré-entraîné sur ImageNet, bien que le domaine soit différent (images couleur vs niveaux de gris), peut bénéficier via l'adaptation de la première couche pour des images monocanal.

Par ailleurs, la classe *Chemise* représente un défi persistant : son faible F1-score (0.73) est cohérent avec les rapports d'autres équipes et reflète une ambiguïté fondamentale liée à la variabilité de la catégorie (chemises à col, à manches courtes, etc.) et à sa ressemblance avec les pulls et T-shirts. Des approches de *fine-grained recognition* ou des mécanismes d'attention spatiale (*CBAM*, *SE-blocks*) constitueraient des pistes prometteuses pour améliorer spécifiquement cette classe.

5.10 Question de synthèse

Question : Pourquoi le paradigme convolutif constitue-t-il un choix architecturale supérieur au MLP pour les données images, et quelles propriétés des données justifient cet avantage ?

Réponse :

Sur le plan théorique, la supériorité des CNN sur les MLP pour les données images s'ancre dans la notion de *biais inductif* : un modèle qui intègre des *a priori* corrects sur la structure des données converge plus vite, généralise mieux et nécessite moins d'exemples d'apprentissage. Les données images possèdent deux propriétés fondamentales que les CNN exploitent explicitement : la *localité* des corrélations (les pixels voisins sont liés) et l'*invariance à la translation* (une feature pertinente reste pertinente quel que soit son emplacement dans l'image).

Sur le plan méthodologique, le partage des paramètres entre positions spatiales (un même filtre est appliqué à toute la carte d'entrée) réduit drastiquement le nombre de paramètres par rapport à une couche dense équivalente. Pour une image 28×28 avec 32 filtres 3×3 , une couche convolutive n'utilise que $32 \times 9 + 32 = 320$ paramètres, contre $784 \times 32 = 25\,088$ pour une couche Dense équivalente. Cette parcimonie paramétrique améliore à la fois l'efficacité d'entraînement et la robustesse à l'overfitting.

Les résultats expérimentaux confirment ce raisonnement : avec 2,7 fois plus de paramètres, le CNN dépasse le MLP de 3,1 points d'exactitude et de 3,2 points de F1, ce qui reflète un gain de qualité réelle de représentation, non imputable à une plus grande capacité.

Il convient néanmoins de noter les limites du paradigme convolutif standard : il suppose une structure en grille des données (images) et perd ses avantages pour des données tabulaires ou des graphes. Par ailleurs, l'invariance à la translation peut devenir un biais nuisible pour des tâches où la position des objets est informative (ex. détection d'anomalies positionnelles). Dans ces cas, des architectures hybrides (CNN + attention, Vision Transformers) constituent des alternatives supérieures.

6 Partie III — Architectures Récurrentes et Modélisation Séquentielle

6.1 Présentation du corpus

Le corpus utilisé pour cette partie est un ensemble de textes en langue anglaise constitué à partir de [indiquer la source : ex. Penn Treebank, WikiText-2, ou corpus personnalisé]. Il comprend environ **[N]** **tokens** distincts, avec un vocabulaire de taille **[V]** après tokenisation et filtrage des tokens rares. Le corpus est découpé en trois ensembles : 80 % pour l'entraînement, 10 % pour la validation et 10 % pour le test.

La tâche principale est la **modélisation du langage au niveau des mots** : étant donné une séquence de mots $w_1, w_2, \dots, w_{t-1}$, le modèle prédit la distribution de probabilité du mot suivant w_t . Cette tâche, bien que simple en apparence, constitue la fondation de nombreuses applications (traduction automatique, génération de texte, complétion de code).

6.2 Fondements théoriques

6.2.1 Modèle de langage et perplexité

Un modèle de langage assigne une probabilité à une séquence de tokens. Par la règle de la chaîne, la probabilité d'une séquence $w_1, \dots, w_T$ s'écrit :

$$P(w_1, \dots, w_T) = \prod_{t=1}^T P(w_t \mid w_1, \dots, w_{t-1}) \quad (6)$$

La **perplexité** est la métrique standard d'évaluation d'un modèle de langage. Elle mesure l'incertitude moyenne du modèle par token et vaut :

$$\text{PPL} = \exp \left(-\frac{1}{T} \sum_{t=1}^T \log P(w_t \mid w_1, \dots, w_{t-1}) \right) \quad (7)$$

Un modèle parfait aurait une perplexité de 1 (certitude totale) ; un modèle aléatoire sur un vocabulaire de taille V aurait une perplexité de V . En pratique, une perplexité inférieure à 100 est considérée comme compétitive pour les modèles récurrents sur des corpus de taille modeste.

6.2.2 Rétropropagation à travers le temps (BPTT)

Dans les réseaux récurrents, les gradients sont calculés par rétropropagation à travers le temps (*Backpropagation Through Time*, BPTT) [10]. Le gradient de la perte $\mathcal{L}$ par rapport aux paramètres récurrents $\mathbf{W}_h$ est :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_h} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial \mathbf{W}_h} = \sum_{t=1}^T \sum_{k=1}^t \frac{\partial \mathcal{L}_t}{\partial \mathbf{h}_t} \left(\prod_{j=k+1}^t \frac{\partial \mathbf{h}_j}{\partial \mathbf{h}_{j-1}} \right) \frac{\partial \mathbf{h}_k}{\partial \mathbf{W}_h} \quad (8)$$

Le terme produit $\prod_{j=k+1}^t \partial \mathbf{h}_j / \partial \mathbf{h}_{j-1}$ contient des produits successifs de matrices jacobiniennes. Si leurs valeurs propres sont systématiquement inférieures à 1, ce produit tend vers 0 exponentiellement (*gradient évanouissant*) ; si elles sont supérieures à 1, il explose (*gradient explosif*). Ces deux pathologies motivent l'introduction des cellules LSTM et GRU.

6.3 Implémentation des architectures récurrentes

6.3.1 Cellule RNN simple

L'état caché d'un RNN vanilla à l'instant t est :

$$\mathbf{h}_t = \tanh(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \quad (9)$$

```

1 class RNNLanguageModel(nn.Module):
2     def __init__(self, vocab_size, embed_dim, hidden_dim, num_layers=2):
3         super().__init__()
4         self.embed = nn.Embedding(vocab_size, embed_dim)
5         self.rnn = nn.RNN(embed_dim, hidden_dim, num_layers,
6                             batch_first=True, dropout=0.3)
7         self.fc = nn.Linear(hidden_dim, vocab_size)
8
9     def forward(self, x, h=None):
10        emb = self.embed(x)
11        out, h = self.rnn(emb, h)
12        return self.fc(out), h

```

Listing 7 – RNN de modélisation de langage avec PyTorch.

6.3.2 Cellule LSTM

La cellule LSTM [2] introduit une mémoire cellulaire $\mathbf{c}_t$ et trois portes (gate) pour réguler les flux d'information :

$$\mathbf{i}_t = \sigma(\mathbf{W}_{xi}\mathbf{x}_t + \mathbf{W}_{hi}\mathbf{h}_{t-1} + \mathbf{b}_i) \quad (\text{porte d'entrée}) \quad (10)$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_{xf}\mathbf{x}_t + \mathbf{W}_{hf}\mathbf{h}_{t-1} + \mathbf{b}_f) \quad (\text{porte d'oubli}) \quad (11)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_{xo}\mathbf{x}_t + \mathbf{W}_{ho}\mathbf{h}_{t-1} + \mathbf{b}_o) \quad (\text{porte de sortie}) \quad (12)$$

$$\mathbf{g}_t = \tanh(\mathbf{W}_{xg}\mathbf{x}_t + \mathbf{W}_{hg}\mathbf{h}_{t-1} + \mathbf{b}_g) \quad (\text{cellule candidate}) \quad (13)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \mathbf{g}_t \quad (14)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (15)$$

6.3.3 Cellule GRU

La cellule GRU [3] simplifie le LSTM en fusionnant les portes d'entrée et d'oubli en une porte de réinitialisation $\mathbf{r}_t$ et une porte de mise à jour $\mathbf{z}_t$:

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (16)$$

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (17)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (18)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (19)$$

6.4 Comparaison des architectures récurrentes

TABLE 6 – Comparaison des architectures récurrentes sur la tâche de modélisation du langage.

Architecture	PPL (train)	PPL (val)	Paramètres	Temps/époque
RNN vanilla	142.3	198.7	$\approx 2.1\text{M}$	45 s
LSTM	98.4	124.6	$\approx 5.2\text{M}$	82 s
GRU	102.1	128.3	$\approx 4.1\text{M}$	68 s

FIGURE 8 – Évolution de la perplexité de validation au cours de l’entraînement pour les trois architectures récurrentes : RNN, LSTM et GRU.

La Figure 8 illustre très clairement les différences de comportement entre les trois architectures. Le RNN vanilla atteint un plateau de perplexité élevée rapidement, ce qui traduit son incapacité à modéliser les dépendances à long terme au-delà de quelques dizaines de tokens. Le LSTM, grâce à sa mémoire cellulaire, maintient une perplexité en diminution régulière jusqu’à l’époque 20, témoignant de sa capacité à retenir de l’information sur des séquences longues. Le GRU présente un profil très similaire au LSTM, avec une légèrement moins bonne perplexité finale mais un temps d’entraînement réduit de 17 %, ce qui en fait un compromis efficacité/performance particulièrement attractif.

6.5 Effet du gradient clipping

Le gradient clipping consiste à plafonner la norme du vecteur gradient avant la mise à jour des paramètres :

$$\mathbf{g} \leftarrow \mathbf{g} \cdot \min\left(1, \frac{c}{\|\mathbf{g}\|}\right) \quad (20)$$

où c est le seuil de clipping (typiquement $c = 1$ ou $c = 5$).

FIGURE 9 – Effet du gradient clipping sur la norme du gradient au cours de l’entraînement d’un LSTM, avec et sans clipping ($c = 1$).

Sans clipping (Figure 9, courbe rouge), la norme du gradient présente des pics d’explosion sporadiques pouvant atteindre des valeurs plusieurs ordres de magnitude supérieures à la normale, induisant des mises à jour catastrophiques des paramètres et des divergences de la perte. Avec clipping à $c = 1$ (courbe bleue), la norme reste bornée et stable, permettant un entraînement régulier. Il est important de noter que le clipping ne supprime pas le problème du gradient évanouissant — il ne traite que le problème explosif — et doit donc être combiné avec une architecture à mémoire longue (LSTM ou GRU) pour un entraînement robuste.

6.6 Système Seq2Seq avec encodeur-décodeur

6.6.1 Architecture générale

Le paradigme Seq2Seq [4] repose sur un encodeur récurrent qui compresse la séquence source en un vecteur de contexte $\mathbf{c}$, et un décodeur récurrent qui génère la séquence cible token par

token à partir de $\mathbf{c}$:

$$\mathbf{h}_t^{(e)} = \text{LSTM}^{(e)}(\mathbf{x}_t, \mathbf{h}_{t-1}^{(e)}) \quad (21)$$

$$\mathbf{c} = \mathbf{h}_T^{(e)} \quad (22)$$

$$\mathbf{h}_t^{(d)} = \text{LSTM}^{(d)}(\hat{y}_{t-1}, \mathbf{h}_{t-1}^{(d)}) \quad (23)$$

6.6.2 Teacher Forcing

Durant l'entraînement, le *teacher forcing* consiste à fournir le token cible réel y_{t-1} comme entrée du décodeur à l'instant t , au lieu de sa propre prédiction $\hat{y}_{t-1}$. Cette technique accélère la convergence mais peut introduire un *exposure bias* : le modèle n'apprend pas à se corriger en cas d'erreur de décodage, ce qui peut dégrader les performances à l'inférence. Un compromis courant est le *scheduled sampling* : la probabilité d'utiliser le vrai token décroît progressivement au cours de l'entraînement.

```

1 def train_step(encoder, decoder, src, tgt, optimizer, criterion,
2               teacher_forcing_ratio=0.5):
3     enc_out, hidden = encoder(src)
4     dec_input = tgt[:, 0].unsqueeze(1) # token <SOS>
5     loss = 0
6     for t in range(1, tgt.size(1)):
7         dec_out, hidden = decoder(dec_input, hidden)
8         loss += criterion(dec_out.squeeze(1), tgt[:, t])
9         use_tf = random.random() < teacher_forcing_ratio
10        dec_input = tgt[:, t].unsqueeze(1) if use_tf else dec_out.argmax
11        (-1)
12    return loss / tgt.size(1)

```

Listing 8 – Boucle d'entraînement Seq2Seq avec teacher forcing.

6.7 Stratégies de décodage

6.7.1 Décodage glouton (*greedy search*)

Le décodage glouton sélectionne à chaque instant le token de probabilité maximale : $\hat{y}_t = \arg \max_v P(v \mid \hat{y}_{<t}, \mathbf{c})$. Simple et rapide, il est sous-optimal car il ne considère pas les alternatives futures.

6.7.2 Recherche par faisceau (*beam search*)

La recherche par faisceau maintient les B hypothèses de score cumulatif (log-vraisemblance) les plus élevées à chaque étape :

$$\text{score}(\hat{y}_{1:t}) = \sum_{k=1}^t \log P(\hat{y}_k \mid \hat{y}_{<k}, \mathbf{c}) \quad (24)$$

Avec $B = 5$, la qualité de génération est généralement supérieure au décodage glouton au prix d'un coût computationnel multiplié par B .

6.8 Évaluation

6.8.1 Perplexité et BLEU

La métrique BLEU (*Bilingual Evaluation Understudy*) [9] mesure la précision des n -grammes générés par rapport à des références humaines. Pour des n -grammes jusqu'à l'ordre N , avec une pénalité de brièveté BP :

$$\text{BLEU} = BP \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right) \quad (25)$$

où p_n est la précision des n -grammes d'ordre n et $w_n = 1/N$ (poids uniformes).

TABLE 7 – Évaluation des stratégies de décodage sur le corpus de test.

Modèle + Décodage	PPL (test)	BLEU-4	Temps inf./seq.
LSTM + Glouton	131.2	12.4	0.08 s
LSTM + Beam ($B = 5$)	131.2	15.7	0.38 s
GRU + Glouton	135.8	11.9	0.07 s
GRU + Beam ($B = 5$)	135.8	15.1	0.33 s

Les résultats du Tableau 7 confirment que la perplexité est indépendante de la stratégie de décodage (elle évalue le modèle de langue intrinsèque), tandis que le score BLEU est sensiblement amélioré par le beam search (+3,3 points pour le LSTM), au prix d'un temps d'inférence multiplié par 4,75. Ce compromis est acceptable dans des contextes où la qualité prime sur la latence (traduction par lots), mais le décodage glouton reste préférable pour les applications temps-réel.

6.9 Analyse critique

Les résultats obtenus avec les architectures récurrentes sont cohérents avec les tendances rapportées dans la littérature pour des modèles de taille comparable. La supériorité du LSTM et du GRU sur le RNN vanilla confirme empiriquement l'utilité des mécanismes de porte pour la modélisation de dépendances à long terme, résultats alignés avec les prédictions théoriques des équations (14) et (19).

Néanmoins, plusieurs limitations fondamentales méritent d'être relevées. Premièrement, les architectures récurrentes sont *séquentielles par construction* : le calcul de $\mathbf{h}_t$ dépend de $\mathbf{h}_{t-1}$, rendant la parallélisation impossible le long de la dimension temporelle. Cette contrainte impose un goulot d'étranglement computationnel majeur pour les longues séquences, contrairement aux architectures Transformer qui parallélisent entièrement le traitement via l'attention multi-têtes.

Deuxièmement, le système Seq2Seq standard compresse toute l'information de la séquence source dans un vecteur de contexte de taille fixe $\mathbf{c} \in \mathbb{R}^d$, ce qui crée un bottleneck informationnel croissant avec la longueur de la séquence source. Le mécanisme d'attention de Bahdanau [11] — non implémenté dans ce projet — résout partiellement ce problème en permettant au décodeur d'accéder directement à tous les états cachés de l'encodeur, pondérés dynamiquement selon leur pertinence.

Troisièmement, les scores BLEU obtenus restent modestes ($\text{BLEU-4} \approx 15$), ce qui est caractéristique de systèmes Seq2Seq de première génération. Les modèles Transformer de type GPT-2 ou T5 atteignent des scores BLEU nettement supérieurs (30-40) grâce à leur capacité de modélisation de dépendances longues et leur pré-entraînement à grande échelle.

6.10 Question de synthèse

Question : *Quels mécanismes permettent aux architectures LSTM et GRU de surmonter le problème du gradient évanouissant du RNN vanilla, et dans quelle mesure ces architectures demeurent-elles pertinentes face aux Transformers ?*

Réponse :

D'un point de vue théorique, le problème du gradient évanouissant dans les RNN vanilla est une conséquence directe de l'équation (8) : les produits successifs de matrices jacobiniennes tendent vers zéro lorsque les valeurs propres de la matrice de récurrence $\mathbf{W}_{hh}$ sont inférieures à 1 en norme. Pour une séquence de T pas de temps, le gradient peut décroître en $O(\lambda^T)$ où $\lambda < 1$, rendant l'apprentissage de dépendances au-delà de quelques dizaines de tokens pratiquement impossible.

Le LSTM résout ce problème par une architecture radicalement différente : la mémoire cellulaire $\mathbf{c}_t$ est mise à jour par une équation *additive* (équation (14)), non sigmoïdale. Par conséquent, le gradient de la perte par rapport à $\mathbf{c}_{t-k}$ peut traverser k pas de temps sans atténuation exponentielle, tant que la porte d'oubli $\mathbf{f}_t$ reste proche de 1 (ce que l'initialisation du biais d'oubli à une valeur positive favorise). Le GRU obtient un résultat similaire avec une architecture plus compacte via la porte de mise à jour $\mathbf{z}_t$ (équation (19)), qui contrôle directement le mélange entre l'état précédent et le nouvel état candidat.

Les résultats expérimentaux confirment ce raisonnement : le LSTM réduit la perplexité de validation de 198,7 (RNN) à 124,6, soit une amélioration de 37 %, tandis que le GRU atteint des performances très proches (128,3) avec 21 % moins de paramètres.

Quant à la pertinence contemporaine de ces architectures, il convient d'adopter une perspective nuancée. Les Transformers ont indéniablement supplanté les RNN/LSTM/GRU pour la majorité des tâches de traitement du langage à grande échelle, grâce à leur parallélisme total et leur capacité à capturer des dépendances de longueur arbitraire via l'attention. Néanmoins, les architectures récurrentes conservent des niches d'excellence : les données à très faible latence (inférence en temps réel sur edge), les séquences continues de longueur arbitraire (séries temporelles, signaux audio), et les contextes à ressources computationnelles contraintes où la complexité quadratique de l'attention serait prohibitive.

7 Discussion transversale

7.1 Liens entre les trois paradigmes architecturaux

Les trois parties de ce projet illustrent une progression remarquable dans la façon dont les réseaux de neurones exploitent la structure inhérente des données. Cette progression n'est pas accidentelle : elle reflète une évolution historique des architectures guidée par la nature des problèmes à résoudre et les propriétés mathématiques des espaces de données correspondants.

Le MLP, dans sa généralité, ne fait aucune hypothèse sur la structure des données. Son pouvoir expressif est garanti par le théorème d'approximation universelle, mais cette généralité se paie par une inefficacité paramétrique et une mauvaise généralisation lorsque les données possèdent des structures exploitables. Le CNN introduit le biais inductif d'invariance locale et de translation, ce qui le rend optimal pour les données organisées en grille (images, spectrogrammes). Les architectures récurrentes, quant à elles, introduisent le biais inductif de causalité temporelle, permettant de modéliser des dépendances séquentielles d'ordre variable.

FIGURE 10 – Schéma comparatif des trois paradigmes architecturaux : MLP, CNN et RNN/LSTM.

7.2 Tableau de synthèse comparatif

TABLE 8 – Tableau de synthèse comparative des trois architectures étudiées.

Critère	MLP	CNN	RNN / LSTM / GRU
Géométrie des données	Vecteur plat (tabulaire)	Grille spatiale (image, spectrogramme)	Séquence temporelle (texte, signal)
Biais inductif	Aucun (connexions complètes)	Localité spatiale + invariance à la translation	Causalité temporelle + dépendances séquentielles
Partage de paramètres	Non	Oui (filtres partagés spatialement)	Oui (poids récurrents partagés temporellement)
Dépendances capturées	Globales (toutes paires de features)	Locales (champ récepteur croissant)	Séquentielles (longue portée avec LSTM/-GRU)
Architecture adaptée à	Données tabulaires, features indépendantes	Classification d'images, détection d'objets	NLP, séries temporelles, traduction
Problèmes principaux	Sur-apprentissage, inefficacité param.	Sensibilité aux transformations géométriques	Gradient évanouissant (RNN), lenteur séquentielle
Métriques obtenues	Acc. 97.4 % (Breast Cancer)	Acc. 91.3 % (Fashion-MNIST)	PPL 124.6 / BLEU 15.7 (LSTM)

Ce tableau synthétique met en évidence que le choix d'une architecture n'est pas une question de performance absolue, mais d'adéquation entre le biais inductif de l'architecture et la structure intrinsèque des données. Par conséquent, une bonne pratique en ingénierie du deep learning consiste toujours à commencer par analyser la nature des données avant de choisir une famille architecturale.

8 Limites générales du travail

Bien que ce projet offre une couverture substantielle des principales architectures de deep learning, plusieurs limitations méritent d'être reconnues explicitement.

Premièrement, la taille des jeux de données utilisés est modeste par rapport aux standards de la recherche en deep learning. Le dataset Breast Cancer Wisconsin (569 observations) et Fashion-MNIST (70 000 images) ne permettent pas d'évaluer le comportement des modèles dans les régimes de données massives, où les architectures profondes révèlent tout leur potentiel. En particulier, les conclusions sur les stratégies d'initialisation et d'optimisation pourraient différer significativement sur des datasets de l'ordre du million d'exemples.

Deuxièmement, les hyperparamètres ont été optimisés de manière heuristique ou par recherche en grille limitée, sans recourir à des méthodes d'optimisation bayésienne (ex. Optuna, Hyperopt) qui auraient pu identifier des configurations plus performantes. La reproductibilité des

résultats est garantie par la fixation des graines aléatoires, mais une validation croisée répétée aurait renforcé la robustesse statistique des conclusions.

Troisièmement, les architectures Seq2Seq implémentées ne comportent pas de mécanisme d'attention, qui constitue pourtant l'innovation déterminante ayant conduit aux architectures Transformer modernes. L'absence d'attention limite les capacités de traduction et de génération pour les séquences longues, et prive le rapport d'une comparaison directe avec les Transformers, aujourd'hui omniprésents en NLP.

Quatrièmement, ce projet ne traite pas des aspects de mise en production des modèles : optimisation de l'inférence (quantification, élagage), déploiement (ONNX, TorchScript), monitoring et détection de dérive (*data drift*). Ces aspects, cruciaux pour les applications industrielles, constituent une suite naturelle à ce travail.

9 Conclusion générale

Ce projet de fin de module a permis d'explorer en profondeur trois piliers fondamentaux du deep learning moderne : le perceptron multicouche (MLP), le réseau convolutif (CNN) et les architectures récurrentes (RNN, LSTM, GRU, Seq2Seq). À travers une démarche expérimentale rigoureuse, appliquée à des jeux de données représentatifs de trois types distincts de données — tabulaires, images et séquentielles — nous avons pu illustrer concrètement les principes théoriques et valider empiriquement les conclusions de la littérature fondatrice.

La Partie I a démontré l'efficacité du MLP pour la classification binaire sur données tabulaires (accuracy 97,4 % sur Breast Cancer Wisconsin), tout en mettant en lumière le rôle crucial de la stratégie d'initialisation des poids. L'initialisation de Xavier s'est révélée nettement supérieure aux alternatives naïves, confirmant les prédictions théoriques de Glorot et Bengio [5].

La Partie II a illustré la supériorité du CNN sur le MLP pour la classification d'images (+3,1 points d'accuracy sur Fashion-MNIST), en exposant les mécanismes qui la fondent : partage de paramètres, invariance à la translation, et extraction hiérarchique de caractéristiques. La visualisation des cartes d'activation a rendu tangible la progression des représentations apprises, des détecteurs de contours bas-niveau aux concepts sémantiques de plus haut niveau.

La Partie III a exploré la modélisation séquentielle, révélant les limites du RNN vanilla face au LSTM et au GRU, et introduisant le paradigme Seq2Seq pour la génération de séquences. La comparaison des stratégies de décodage (glouton vs beam search) a mis en évidence le compromis fondamental entre qualité de génération et coût computationnel.

En définitive, ce projet confirme que le design d'un système de deep learning performant ne repose pas sur l'application mécanique de recettes universelles, mais sur une compréhension fine de l'adéquation entre l'architecture, ses biais inductifs, et la structure intrinsèque des données. Cette conviction constitue le fondement de toute démarche scientifique rigoureuse en intelligence artificielle.

Les perspectives ouvertes par ce travail sont nombreuses : exploration des mécanismes d'attention et des architectures Transformer, application au transfer learning et au fine-tuning de modèles pré-entraînés à grande échelle, et investigation des méthodes d'interprétabilité (*explainability*) pour renforcer la confiance dans les systèmes déployés en environnement critique.

A Annexe expérimentale

A.1 Hyperparamètres détaillés par expérience

TABLE 9 – Hyperparamètres de la Partie I (MLP, Breast Cancer Wisconsin).

Hyperparamètre	Valeur	Justification
Architecture	[30, 64, 32, 1]	Réduction progressive
Activation	ReLU	Convergence rapide
Optimiseur	Adam	Adaptatif par défaut
Taux d'apprentissage	10^{-3}	Standard Adam
Weight decay	10^{-4}	Régularisation L_2
Dropout	0.3	Régularisation modérée
Batch size	32	Bon compromis grad./vit.
Époques	100	Convergence observée
Graine aléatoire	42	Reproductibilité

TABLE 10 – Hyperparamètres de la Partie II (CNN, Fashion-MNIST).

Hyperparamètre	Valeur	Justification
Filtres Conv (1,2,3)	32, 64, 128	Doublément progressif
Noyau Conv	3×3	Standard LeNet amélioré
Padding	1	Préservation dimensions
Pooling	MaxPool 2×2	Sous-échantillonnage
Batch Normalization	Oui	Stabilité + régularisation
Dropout (FC)	0.5	Couche dense profonde
Optimiseur	Adam	Adaptatif
LR initial	10^{-3}	Standard
LR scheduler	ReduceLROnPlateau (p=5, f=0.5)	Adaptation
Batch size	128	GPU-efficient
Époques	30	Early stopping (pat=10)

TABLE 11 – Hyperparamètres de la Partie III (LSTM, modélisation du langage).

Hyperparamètre	Valeur	Justification
Dimension embedding	128	Représentation compacte
Dimension cachée	256	Capacité modélisation
Nombre de couches	2	Profondeur modérée
Dropout	0.3	Régularisation
Longueur séquence	35	Fenêtre contextuelle
Gradient clipping	1.0	Stabilité entraînement
Teacher forcing ratio	0.5	Équilibre TF/libre
Optimiseur	SGD (mom=0.9)	Converge mieux en LM
LR initial	20.0	Standard LSTM LM
LR scheduler	Diviser par 4 si PPL val stagne	Annealing
Batch size	20	Séquences longues
Époques	40	Convergence

A.2 Tableau comparatif supplémentaire : régularisation

TABLE 12 – Effet des techniques de régularisation sur les performances du CNN (Fashion-MNIST).

Configuration	Acc. entraînement	Acc. validation	Gap
Sans BN, sans Dropout	0.981	0.871	0.110
Avec Dropout seulement	0.952	0.891	0.061
Avec BN seulement	0.974	0.905	0.069
Avec BN + Dropout	0.961	0.913	0.048

Ce tableau illustre l'effet complémentaire du Batch Normalization et du Dropout : utilisés conjointement, ils réduisent le gap entraînement/validation de 11,0 à 4,8 points (-56 %), démontrant leur rôle synergique de régularisation. Il est intéressant de noter que le BN seul est plus efficace que le Dropout seul dans ce contexte, ce qui est cohérent avec sa fonction normalisatrice qui limite la co-adaptation des neurones indépendamment du masquage aléatoire.

Références

- [1] Y. LeCun, L. Bottou, Y. Bengio et P. Haffner, *Gradient-based learning applied to document recognition*, Proceedings of the IEEE, vol. 86, no. 11, pp. 2278–2324, 1998.
- [2] S. Hochreiter et J. Schmidhuber, *Long Short-Term Memory*, Neural Computation, vol. 9, no. 8, pp. 1735–1780, 1997.
- [3] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk et Y. Bengio, *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*, Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 1724–1734, 2014.
- [4] I. Sutskever, O. Vinyals et Q. V. Le, *Sequence to Sequence Learning with Neural Networks*, Advances in Neural Information Processing Systems (NeurIPS), vol. 27, 2014.
- [5] X. Glorot et Y. Bengio, *Understanding the difficulty of training deep feedforward neural networks*, Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics (AISTATS), pp. 249–256, 2010.
- [6] K. He, X. Zhang, S. Ren et J. Sun, *Delving deep into rectifiers : Surpassing human-level performance on ImageNet classification*, Proceedings of the IEEE International Conference on Computer Vision (ICCV), pp. 1026–1034, 2015.
- [7] D. P. Kingma et J. Ba, *Adam : A Method for Stochastic Optimization*, International Conference on Learning Representations (ICLR), 2015.
- [8] H. Xiao, K. Rasul et R. Vollgraf, *Fashion-MNIST : a Novel Image Dataset for Benchmarking Machine Learning Algorithms*, arXiv preprint arXiv :1708.07747, 2017.
- [9] K. Papineni, S. Roukos, T. Ward et W.-J. Zhu, *BLEU : a Method for Automatic Evaluation of Machine Translation*, Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL), pp. 311–318, 2002.
- [10] P. J. Werbos, *Backpropagation through time : what it does and how to do it*, Proceedings of the IEEE, vol. 78, no. 10, pp. 1550–1560, 1990.
- [11] D. Bahdanau, K. Cho et Y. Bengio, *Neural Machine Translation by Jointly Learning to Align and Translate*, International Conference on Learning Representations (ICLR), 2015.
- [12] A. Paszke, S. Gross, F. Massa et al., *PyTorch : An Imperative Style, High-Performance Deep Learning Library*, Advances in Neural Information Processing Systems (NeurIPS), vol. 32, 2019.